
Projet Population : Base de Données des Recensements Français (1968-2020)

BONICEL Basile, DUCARUGE Oscar, JIENU Bryan

Février 2026

Résumé

Ce projet présente la conception et l'implémentation d'une base de données MySQL pour l'analyse de la population française de 1968 à 2020. Les données sont issues des recensements de l'INSEE et sont organisées selon une structure relationnelle permettant des analyses par villes, départements et régions. L'importation des données est réalisée via Python et la librairie Pandas.

Sommaire

1	Introduction	3
1.1	Sources de données	3
1.2	Outils utilisés	3
2	Conception de la Base de Données	3
2.1	Modèle Conceptuel de Données (MCD)	3
2.2	Modèle Physique de Données (MPD)	3
2.3	Spécificités territoriales	4
3	Guide d'utilisation	4
3.1	Prérequis	4
3.2	Installation	4
3.3	Exécution des scripts	4
3.4	Exemple d'utilisation	4
3.5	Extraits de code commentés	5
3.6	Requêtes implémentées	5
3.7	Question 2 (5 requêtes inventées)	6
3.8	Résultats clés des requêtes	6
3.9	Statistiques clés de la base	6
3.10	Évolution de la population française	7
3.11	Top 10 des régions par population (2020)	7
3.12	Top 10 des villes par croissance (1968-2020)	7
3.13	Graphique 2 : Répartition par région	8
3.14	Graphiques 3 & 4 : Analyses des villes	8
3.15	Graphique 5 : Top 10 densité	9
3.16	Graphique 6 : Mouvements de population par recensement	9
4	Conclusion	10
4.1	Bilan du projet	10
4.2	Principaux enseignements	10
4.3	Compétences développées	10

1 Introduction

Ce projet de Programmation Analyse (Master 1 MACIA, 2025-2026) vise à concevoir et implémenter une base de données relationnelle pour analyser l'évolution de la population française sur plus de 50 ans (1968-2020). Les objectifs principaux sont : (1) créer un modèle conceptuel adapté, (2) importer les données INSEE via Python, (3) gérer les spécificités territoriales (Corse, DOM-TOM), et (4) réaliser des analyses statistiques.

1.1 Sources de données

Les données utilisées proviennent de l'INSEE (Institut National de la Statistique et des Études Économiques) :

- `populationSerieHistorique2020.csv` : Données démographiques
- `populationDepartementsFrance.csv` : Référentiel des départements
- `populationMetaDataSerieHistorique2020.csv` : Métadonnées

1.2 Outils utilisés

- **SGBD** : MySQL 8.0
- **Langage** : Python 3.11
- **Librairies** : Pandas, SQLAlchemy, mysql-connector-python, Matplotlib

2 Conception de la Base de Données

2.1 Modèle Conceptuel de Données (MCD)

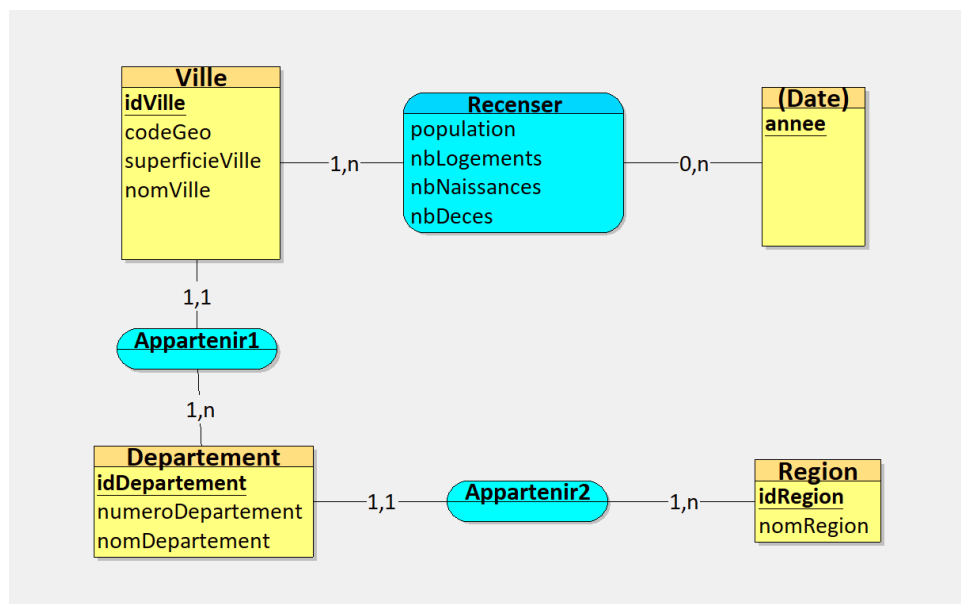


FIGURE 1 – Modèle Conceptuel de Données du projet Population

2.2 Modèle Physique de Données (MPD)

Quatre tables : Region (PK idRegion), Département (PK idDépartement, FK idRegion), Ville (PK idVille, FK idDépartement), Recenser (PK idVille+annee, FK idVille). Voir fichier `creationBDD.sql` pour le code complet.

2.3 Spécificités territoriales

Les données INSEE contiennent des cas spéciaux qui ont nécessité un traitement particulier :

- **Corse** : Codes 2A et 2B → IDs 0 et 20
- **DOM-TOM** : Codes 971-976 → IDs 96-100
- **Correspondance codes géographiques** : Fonction Python `codeToDep()`

3 Guide d'utilisation

3.1 Prérequis

- **SGBD** : MySQL 8.0 ou version supérieure
- **Python** : Version 3.11 ou supérieure
- **Librairies Python** : `mysql-connector-python`, `pandas`, `sqlalchemy`, `matplotlib`

3.2 Installation

1. Créer un fichier `mdp.txt` dans le dossier `src/python/` contenant le mot de passe MySQL :

```
echo "votre_mot_de_passe" > src/python/mdp.txt
```

2. Installer les dépendances Python :

```
pip install mysql-connector-python pandas sqlalchemy matplotlib
```

3.3 Exécution des scripts

Tout le projet peut être visualisé en exécutant le fichier `main.py` qui fait lui même appel aux différents fichier python du projet :

- `connexion.py` : Établi la connexion avec le serveur SQL
- `import_data.py` : Crée la base de donnée et la remplit avec les fichiers CSV
- `requetes.py` : Effectue les différentes requêtes du projet
- `graphique.py` : Génère différents graphiques à partir de certaines requêtes et les enregistre dans le dossier `graphiques` à la racine du projet

3.4 Exemple d'utilisation

```
1 from connexion import connexionBDD
2 from requetes import *
3
4 # Connexion a la base de donnees
5 cnx = connexionBDD()
6
7 # Execution d'une requete
8 resultat = requete_simple(cnx, requete_a())
9 afficher_resultat(resultat)
10
11 # Generation d'un graphique
12 from graphique import graph_evolution_france
13 graph_evolution_france(cnx)
```

3.5 Extraits de code commentés

Gestion de la Corse et DOM-TOM : La fonction `codeToDep()` gère la conversion des codes géographiques :

```

1 codeToDepDict = {
2     "971": 96, "972": 97, "973": 98,
3     "974": 99, "976": 100,
4     "2A": 0, "2B": 20
5 }
6
7 def codeToDep(df):
8     df = str(df)
9     if len(df) == 4:
10        return int(df[0])
11    for k in (df[:3], df[:2]):
12        try:
13            return codeToDepDict[k]
14        except KeyError:
15            pass
16    return int(df[:2])

```

Création des vues : Pour éviter de compter Paris deux fois (ville + 20 arrondissements), deux vues ont été créées :

```

1 CREATE VIEW villeSeule AS (
2     SELECT * FROM Ville
3     WHERE LOWER(nomVille) NOT LIKE "%arrondissement"
4 );
5
6 CREATE VIEW arrondissement AS (
7     SELECT * FROM Ville
8     WHERE LOWER(nomVille) LIKE "%arrondissement"
9 );

```

Fonctionnement de `creationBDD.py` : Le script importe les données en 8 étapes : création BDD, tables, import CSV régions/départements/villes (avec gestion Corse/DOM-TOM), recensements, et création des vues.

3.6 Requêtes implémentées

- a) Liste des populations en 2020 par ville, département, région
- b) Évolution de la population française (1968-2020)
- c) Populations 2020 par département et par région
- d) Population de Paris (ville + arrondissements)
- e) Top 10 villes/départements/régions par croissance (1968-2020)
- f) Top 10 villes/départements par naissances et décès
- g) Top 10 villes/départements par densité
- h) Comparaison 2020 : naissances, décès, mouvements
- i) Comparaison par recensement : France

3.7 Question 2 (5 requêtes inventées)

- 1) Nombre de villes en Normandie (GROUP BY) : **2 651 communes**
- 2) Nombre de villes par région (GROUP BY) : Île-de-France en tête avec 1 268 communes
- 3) TOP 10 Villes DOM-TOM 1990 (WHERE LIKE '97%') : Saint-Denis (122 000), Fort-de-France (100 080), Saint-Paul (71 669)
- 4) Villes Creuse > moyenne française 2020 (sous-requête AVG) : 5 villes dont Guéret (12 698), La Souterraine (4 953), Aubusson (3 181)
- 5) Top 10 ratio décès/population (WITH + JOIN) : Communes rurales vieillissement rapide

3.8 Résultats clés des requêtes

Ville	Pop.	Naiss.	Décès
Paris	2 146K	1 646K	1 021K
Marseille	870K	608K	443K
Lyon	522K	359K	212K
Toulouse	498K	296K	152K
Nice	343K	214K	222K

Année	Pop.
1968	50,8M
2020	67,2M

Dép.	Pop.
Nord	2 608K
Paris	2 146K
Bouches-du-Rhône	2 048K

Région	Pop.
Île-de-France	12 272K
Auvergne-Rhône-Alpes	8 079K
Nouvelle-Aquitaine	6 034K

Ville	Croiss.
Montpellier	+137K
Toulouse	+127K
Saint-Denis (Réunion)	+68K
Cergy	+65K
Saint-Paul (Réunion)	+61K

Dép.	Croiss.
Seine-et-Marne	+824K
Haute-Garonne	+725K
Essonne	+633K
Gironde	+627K
Hérault	+598K

Ville	Dens.
Vincennes	2 419K
Levallois-Perret	2 403K
Saint-Mandé	2 282K
Le Pré-St-Gervais	2 247K
Montrouge	2 082K

Inv.	Résultat
Normandie	2 651 com.
Île-de-France	1 268 com.
DOM-TOM 1990	Saint-Denis : 122K
Creuse > moy.	5 villes

3.9 Statistiques clés de la base

- **Nombre de régions** : 18
- **Nombre de départements** : 101 (France métropolitaine + DOM-TOM)
- **Nombre de communes** : 34 973
- **Période couverte** : 1968 à 2020 (11 recensements)
- **Population France 2020** : 67,2 millions d'habitants
- **Population France 1968** : 50,8 millions
- **Croissance 1968-2020** : +16,4 millions (+32%)

3.10 Évolution de la population française




FIGURE 2 – Évolution de la population française de 1968 à 2020

La population française est passée de 50,8 millions (1968) à 67,2 millions (2020), soit une croissance de +32% sur 52 ans.

3.11 Top 10 des régions par population (2020)

1. Île-de-France : 12,3 millions
2. Auvergne-Rhône-Alpes : 8,1 millions
3. Nouvelle-Aquitaine : 6,0 millions
4. Hauts-de-France : 6,0 millions
5. Occitanie : 6,0 millions
6. Grand Est : 5,6 millions
7. Provence-Alpes-Côte d'Azur : 5,1 millions
8. Pays de la Loire : 3,8 millions
9. Bretagne : 3,4 millions
10. Normandie : 3,3 millions

3.12 Top 10 des villes par croissance (1968-2020)

1. Montpellier : +137 186 hab.
2. Toulouse : +127 207 hab.
3. Saint-Denis (La Réunion) : +67 557 hab.
4. Cergy : +64 895 hab.
5. Saint-Paul (La Réunion) : +61 172 hab.
6. Nantes : +60 488 hab.
7. Évry-Courcouronnes : +58 814 hab.
8. Aix-en-Provence : +57 556 hab.
9. Annecy : +53 500 hab.
10. Le Tampon (La Réunion) : +49 400 hab.

3.13 Graphique 2 : Répartition par région




FIGURE 3 – Répartition de la population française par région (2020)

Ce graphique en barres montre la répartition de la population entre les différentes régions françaises. L'Île-de-France domine avec 12,3M d'habitants, suivie d'Auvergne-Rhône-Alpes (8,1M), Nouvelle-Aquitaine (6,0M) et Hauts-de-France (6,0M). Note : les arrondissements parisiens sont exclus via la vue villeSeule.

3.14 Graphiques 3 & 4 : Analyses des villes




FIGURE 4 – Top 10 croissance (1968-2020)




FIGURE 5 – Top 10 naissances (1968-2020)

Figure 4 – Top 10 croissance (1968-2020) : Ce graphique révèle les villes ayant connu la plus forte croissance démographique sur 52 ans. Montpellier (+137 186 hab.) et Toulouse (+127 207 hab.) dominent largement, témoignant de l'attractivité des métropoles du Sud. On note aussi la présence de trois villes de La Réunion (Saint-Denis, Saint-Paul, Le Tampon) dans le top 10, illustrant la forte croissance démographique des DOM-TOM.

Figure 5 – Top 10 naissances (1968-2020) : Ce graphique présente les villes comptabilisant le plus de naissances sur la période. Paris domine avec 1,6 million de naissances, suivi de Marseille (608 000) et Lyon (359 000). Les grandes métropoles régionales (Toulouse, Nantes, Nice, Strasbourg, Lille) complètent ce classement, confirmant la concentration des naissances dans les pôles urbains majeurs.

3.15 Graphique 5 : Top 10 densité




FIGURE 6 – Top 10 des villes avec la plus grande densité de population

Ce graphique est dominé par les villes de la petite couronne parisienne : Vincennes (2,4M hab/km²), Levallois-Perret (2,4M), Saint-Mandé (2,3M), Le Pré-Saint-Gervais (2,2M), Montrouge (2,1M), Boulogne-Billancourt (1,8M). Ces communes témoignent d'une urbanisation très dense concentrée autour de Paris.

3.16 Graphique 6 : Mouvements de population par recensement




FIGURE 7 – Mouvements de population par année de recensement

Solde migratoire par période : 1975 (+726K), 1982 (+185K), 1990 (+483K), 1999 (+51K), 2009 (+1,5M), 2014 (+272K), 2020 (+198K). Le pic de 2009 correspond à l'immigration liée à la crise économique.

4 Conclusion

4.1 Bilan du projet

Ce projet nous a permis de mettre en pratique :

- **Conception** : Modélisation MCD et MPD adaptée aux données réelles
- **Implémentation** : Création d'une base MySQL avec contraintes d'intégrité (4 tables, 2 vues)
- **ETL** : Chargement de 36 681 communes avec Pandas et SQLAlchemy
- **Requêtes avancées** : 19 requêtes SQL avec JOIN, GROUP BY, WITH, sous-requêtes
- **Gestion des cas spéciaux** : Corse (2A/2B), DOM-TOM (971-976)

4.2 Principaux enseignements

- **Croissance démographique** : La France gagne en moyenne 316 000 habitants par an
- **Déséquilibres territoriaux** : Pôles urbains (Montpellier, Toulouse, Nantes) en forte croissance, ruralité en déclin
- **Vieillesse** : Ratio décès/population en hausse dans les communes rurales (Creuse)
- **Poids de l'Île-de-France** : 18% de la population nationale (12,3M/67,2M)
- **DOM-TOM** : Saint-Denis (La Réunion) dépasse 120 000 hab. dès 1990

4.3 Compétences développées

- Maîtrise de Pandas pour la manipulation de données
- Utilisation de SQLAlchemy pour l'ORM MySQL
- Gestion des transactions et clés étrangères
- Travail collaboratif avec Git

Projet réalisé dans le cadre du Master 1 MACIA - Programmation Analyse